

MACHINE LEARNING & DEEP LEARNING

Diagnosi di Polmonite Infantile da Immagini Radiografiche

Classificazione binaria con SVM e Reti Neurali Convoluzionali
Chest X-Ray Images — Transfer Learning con Xception

STUDENTESSA

Marta Nasso

MATRICOLA

5462414

ESAME

Machine Learning and Deep Learning

A.A.

2025/2026

1 Contesto Clinico
Polmonite infantile e motivazione

3 Split 70/15/15
Training, Validation e Test Set

5 Baseline ML: SVM
Flattening, kernel lineare, metriche

7 Training & Fine-Tuning
Feature Extraction → Fine-Tuning

2 Il Dataset
Chest X-Ray Images (Pneumonia) — Kaggle

4 Campioni & EDA
Visualizzazione radiografie

6 Architettura CNN
Xception + Transfer Learning

8 Valutazione, XAI & Confronto
CM, ROC, Grad-CAM, SVM vs CNN

Contesto Clinico: Polmonite Infantile

La polmonite è una delle principali cause di mortalità nei bambini sotto i 5 anni. La diagnosi precoce tramite radiografia toracica è essenziale, ma richiede personale specializzato spesso non disponibile in aree con risorse limitate.

Il Problema

Interpretazione di radiografie toraciche (CXR) per distinguere polmoni sani da polmoniti batteriche o virali. Task ad alta complessità visiva.

L'Obiettivo

Sistema di classificazione automatica binaria: **NORMAL** vs **PNEUMONIA**, a supporto della diagnosi clinica pediatrica.

Impatto Clinico

Riduzione dei falsi negativi (diagnosi mancate). Prioritizzazione casi critici. Supporto ai medici in contesti a risorse limitate.

2.5M

CASI PEDIATRICI/ANNO (OMS)

>90%

DIAGNOSI AFFIDABILI DA CXR

2 classi

NORMAL VS PNEUMONIA

150px

RISOLUZIONE INPUT RGB

DATI

II Dataset: Chest X-Ray Images (Pneumonia)

Fonte	Kaggle — paulthomothymoney/chest-xray-pneumonia
Dimensione archivio	2.29 GB (download via API Kaggle)
Totale immagini	~5.856 radiografie toraciche pediatriche
Classi	NORMAL • PNEUMONIA (classificazione binaria)
Formato originale	JPEG, scala di grigi (caricato come RGB)
Risoluzione input	150 × 150 px (resize via Keras)
Batch size	32 immagini per batch
Provenienza clinica	Guangzhou Women and Children's Medical Center

PNEUMONIA ~74% (4.273 img)
PNEUMONIA — 4.273

NORMAL ~26% (1.583 img)
NORMAL — 1.583

```
# Download via API Kaggle
!kaggle datasets download
-d paulthomothymoney/
  chest-xray-pneumonia

# Unificazione split originale
!find chest_xray/*/NORMAL
-type f -exec mv {}
dataset_unit0/NORMAL/ ;

!find chest_xray/*/PNEUMONIA
-type f -exec mv {}
dataset_unit0/PNEUMONIA/ ;
```

Suddivisione del Dataset: Split 70 / 15 / 15

70%
Training Set

15%
Validation

15%
Test Set

Training Set (ld)

70%

~129 batch × 32 = ~4.100 img
Aggiornamento pesi del modello

Validation Set (vd)

15%

~878 immagini
Monitoraggio overfitting durante training

Test Set (td)

15%


~878 immagini
Valutazione finale (mai visto dal modello)

SFIDE PRINCIPALI

Validation set insufficiente: la suddivisione originale di Kaggle prevedeva solo 16 immagini nel validation set (8 per classe), statisticamente non rappresentativo — necessaria una ripartizione ex-novo.

Sbilanciamento delle classi: il dataset presenta una proporzione fortemente asimmetrica; lo split è stato eseguito con il parametro `stratify` per preservare tale distribuzione.

Campioni del Dataset: Radiografie Toraciche



Campione rappresentativo del Training Set. Le immagini PNEUMONIA mostrano consolidamenti e opacità polmonari; le NORMAL presentano campi polmonari trasparenti e omogenei.

Modello ML: Support Vector Machine (SVM)

Prima di adottare architetture Deep Learning, viene stabilita una **Baseline con SVM** per giustificare architetaturalmente il passaggio alle CNN e contestualizzare il miglioramento ottenuto.

```
# Flattening: 150x150x3 -> 67.500 feature
X = tf.reshape(images,
    [images.shape[0], -1]).numpy()
X = X / 255.0

# Sub-sample: 20 batch = 640 train img
# 10 batch = 320 test img

svm_model = SVC(
    kernel='linear',
    random_state=42
)
svm_model.fit(X_train, y_train)
```

Pipeline SVM

- 1. Caricamento** — 640 immagini dal Training Set (20 batch)
- 2. Flattening** — reshape (150,150,3) → vettore (67.500, 1)
- 3. Normalizzazione** — pixel / 255.0, valori in [0, 1]
- 4. Training SVM** — kernel lineare, C=1.0 (default)
- 5. Valutazione** — 320 immagini del Test Set

Risultati SVM: Metriche Cliniche

91.56%

Accuratezza Baseline SVM sul Test Set (320 immagini)

Classe	Precision	Recall	F1-Score	Support
Normal	0.86	0.87	0.86	97
Pneumonia	0.94	0.94	0.94	223
Accuracy		0.92		320
Macro avg	0.90	0.90	0.90	320
Weighted avg	0.92	0.92	0.92	320

0.94

RECALL PNEUMONIA

210/223 casi reali
identificati correttamente

0.87

RECALL NORMAL

84/97 casi sani
identificati correttamente

INTERPRETAZIONE CLINICA

- FN** **Recall Pneumonia = 0.94:** 13 polmoniti su 223 classificate come Normal. Basso tasso di falsi negativi — il rischio clinico più grave in ambito pediatrico.
- FP** **Recall Normal = 0.87:** 13 soggetti sani su 97 classificati come Pneumonia. Falsi positivi: esami aggiuntivi non necessari, ma nessun danno diretto.
- FN** **Precision Normal = 0.86:** il 14% delle predizioni “Normal” sono in realtà polmoniti — ulteriori falsi negativi critici da ridurre con la CNN.

Perché passare dalla SVM alle CNN?

✗ **Flattening obbligatorio:** ogni immagine $150 \times 150 \times 3$ viene appiattita in un vettore 1D da **67.500 feature**, perdendo completamente la struttura spaziale.

✗ **Complessità quadratica/cubica:** la SVM non scala su dataset grandi. Addestrata solo su ~640 immagini (20 batch) per limiti di RAM.

✗ **Nessuna gerarchia di feature:** la SVM lavora su pixel grezzi, non impara bordi, texture.

✗ **Falsi negativi critici:** senza feature visive profonde il modello manca casi di polmonite reale — in ambito clinico un falso negativo è più pericoloso di un falso positivo.

✓ **Struttura spaziale preservata:** i layer convoluzionali analizzano l'immagine come griglia 2D, rispettando la posizione relativa dei pixel.


✓ **Feature gerarchiche:** i layer profondi imparano progressivamente bordi → texture → forme → pattern clinici specifici.

✓ **Scalabilità:** gestisce l'intero dataset senza campionamento, sfruttando GPU e batch processing.

✓ **Transfer Learning:** con Xception si riutilizzano 20.86M parametri già addestrati, senza partire da zero.

✗ **Xception (Extreme Inception):** una rete neurale convoluzionale sviluppata da **Google nel 2017**, pre-addestrata su **ImageNet**: 1.4 milioni di immagini suddivise in 1000 categorie. Non la costruiamo da zero — importiamo tutta questa conoscenza e la adattiamo alle radiografie mediche tramite **Transfer Learning**.

CNN: Xception + Transfer Learning



Transfer Learning da ImageNet

Xception ha già imparato bordi, texture e forme su 1.4M immagini naturali. Queste rappresentazioni si trasferiscono alle radiografie: un bordo di opacità polmonare non è così diverso dal bordo di una foglia.

Data Augmentation

RandomFlip orizzontale + RandomRotation (0.1 rad). Crea varianti artificiali ad ogni epoch: la rete impara che la polmonite non dipende dall'orientamento esatto del paziente. Riduce l'overfitting senza aggiungere dati reali.

Normalizzazione specifica Xception

Rescaling pixel $[0, 255] \rightarrow [-1, +1]$. Critico: Xception è stato pre-addestrato con questo range. Usare $[0, 1]$ causerebbe discrepanza nelle attivazioni interne e degraderebbe il Transfer Learning.

GlobalAvgPool vs Flatten

La mappa $5 \times 5 \times 2048$ di Xception viene ridotta a un vettore 2048 con la media spaziale. Più compatto del Flatten (51.200 valori), meno overfitting e più robusto a variazioni di posizione del soggetto.

Training in due fasi: Feature Extraction → Fine-Tuning

Il training avviene in **due fasi sequenziali**. Prima si allena solo il classificatore finale tenendo Xception bloccato, poi si sblocca tutto Xception con un learning rate molto ridotto per adattarlo al dominio radiografico senza distruggere ciò che ha imparato su ImageNet.

Fase 1 — Feature Extraction

Xception congelato · 2.049 params trainable

Epoch	Train Acc	Val Acc
1/4	83.00%	87.27%
2/4	89.85%	89.00%
3/4	91.29%	89.81%
4/4	91.29%	90.16%

- ✓ Convergenza rapida: 83% → 91% in 4 epoche
- ✓ Gap train/val minimo → nessun overfitting
- ✓ ~3s/step grazie al backbone congelato
- ✓ Prova che le feature ImageNet sono utili per le RX

Fase 2 — Fine-Tuning



Xception sbloccato · 20.81M params trainable

Epoch	Train Acc	Val Acc
1/4	84.39%	89.93%
2/4	91.71%	93.75%
3/4	93.20%	94.44%
4/4	94.07%	94.44%

- ✓ Val Acc: 90.16% → 94.44% (+4.28 pp)
- ✓ LR = 1e-5 evita catastrophic forgetting
- ✓ Gap train/val minimo → ottima generalizzazione
- ⚠ ~10s/step (tutti i pesi sbloccati)


Perché $lr = 1e-5$ nel Fine-Tuning? Con il learning rate default ($1e-3$) ogni aggiornamento sarebbe 100× più grande e distruggerebbe in poche iterazioni i 20.8M parametri pre-addestrati su ImageNet — è il **catastrophic forgetting**. Con $lr=1e-5$ si fanno micro-aggiustamenti che adattano Xception alle radiografie senza cancellare ciò che ha imparato su 1.4 milioni di immagini.

Andamento Training: Accuratezza e Loss (Fine-Tuning)



Fase di Fine-Tuning (4 epoche): training acc 84% → 94.07%, val acc 90% → 94.44%. Loss decresce monotonicamente. Gap train-val minimo conferma assenza di overfitting.

Matrice di Confusione sul Test Set




Confusion Matrix — CNN Xception + Fine-Tuning (Test Set)

Lettura Clinica della Matrice

- **Veri Positivi (TP):** polmoniti correttamente identificate → massimizzare per ridurre diagnosi mancate.
- **Falsi Negativi (FN):** polmonite classificata come normale → rischio clinico critico in età pediatrica.
- **Falsi Positivi (FP):** normale classificato come polmonite → esami aggiuntivi non necessari.
- **Veri Negativi (TN):** polmoni sani correttamente identificati.

Metrica prioritaria: nel dominio clinico il **Recall** sulla classe PNEUMONIA è più critico dell'Accuracy globale. Un FN significa una polmonite infantile non trattata.

Curva ROC e Area Under the Curve (AUC)



Curva ROC sul Test Set — AUC misura la capacità discriminante del modello

Interpretazione della Curva ROC

- **AUC = 1.0**: classificatore perfetto
- **AUC = 0.5**: classificatore casuale (linea tratteggiata)
- Il modello CNN mostra AUC **molto prossimo a 1**, confermando eccellente capacità discriminante Normal vs Pneumonia.


Soglia Decisionale

Modello usa `from_logits=True`: soglia predefinita a 0 (logit) $\equiv$ 0.5 in probabilità.


In ambito clinico, abbassare la soglia aumenta il Recall a scapito della Precision, riducendo ulteriormente i falsi negativi (polmoniti non diagnosticate).

Grad-CAM: Interpretabilità del Modello

Radiografia Originale (Polmonite)



Grad-CAM: Focus dell'IA



Sx: radiografia originale (PNEUMONIA). Dx: Grad-CAM — rosso/giallo = zone di massima attenzione della CNN.

Come funziona Grad-CAM

- Grad-CAM calcola i **gradienti del segnale di output** rispetto alle feature map dell'ultimo layer convoluzionale di Xception ($5 \times 5 \times 2048$).
- Le regioni in **rosso/giallo** indicano le zone polmonari che hanno maggiormente influenzato la predizione di Polmonite.
- Risolve il problema della **“Black Box”**: il medico verifica se il modello si concentra sull'area polmonare corretta.
- Implementazione manuale con `tf.GradientTape` per compatibilità con l'architettura funzionale di Xception.

Valore clinico: un radiologo può validare visivamente la diagnosi dell'IA. Se la heatmap evidenzia il parenchima polmonare, la diagnosi è scientificamente giustificabile. Essenziale per l'adozione in contesti ospedalieri.

Confronto: SVM (Baseline) vs CNN Xception

Criterio	SVM (Baseline)	CNN — Xception + Fine-Tuning
Accuratezza Test	91.56%	~95%+ (val 94.44%)
Recall Pneumonia	0.94 (sub-sample)	Superiore su set completo
Training set utilizzato	640 immagini (sub-sample)	~4.100 immagini (intero set)
Invarianza spaziale	No (flat pixel vector)	Sì (conv layers gerarchici)
Data Augmentation	Non applicabile	RandomFlip + RandomRotation
Scalabilità	$O(n^2-n^3)$, RAM critica	$O(n)$, GPU-friendly
Interpretabilità	Support Vectors	Grad-CAM (visuale, clinicamente utile)
Knowledge Transfer	No	ImageNet (20.86M parametri pre-addestrati)

✓ **Verdetto:** la CNN con Xception + Fine-Tuning supera la baseline SVM su tutti i criteri rilevanti. La SVM ha però confermato la fattibilità del task (91.56% senza convoluzioni), **giustificando architetturalmente** il passaggio al Deep Learning per ottenere performance clinicamente affidabili.

Conclusioni

91.56%

SVM BASELINE ACCURACY

94.44%

CNN VAL ACC (FINE-TUNING)

8 ep.

EPOCHS TOTALI (4+4)

20.8M

PARAMETRI XCEPTION

Dataset & Preprocessing

Riorganizzazione del dataset Kaggle con split personalizzato 70/15/15. Superato il Validation Set insufficiente (16 img) dell'originale. Pipeline ottimizzata con cache e prefetch.

Baseline SVM

SVM con kernel lineare raggiunge 91.56% su sub-campione di 640 immagini. Confermata la fattibilità del task. Evidenziate le limitazioni di scalabilità degli approcci ML classici su immagini.

CNN Xception + Transfer Learning

Feature Extraction (2.049 params) → Fine-Tuning (20.8M params). Val Accuracy: 90.16% → 94.44%. Assenza di overfitting in entrambe le fasi. Loss convergente.

Explainability & Impatto Clinico

Grad-CAM rende il modello interpretabile per il personale medico. Il sistema può supportare la diagnosi precoce di polmonite infantile in contesti con risorse limitate.

MACHINE LEARNING & DEEP LEARNING

Grazie per l'attenzione

STUDENTESSA

Marta Nasso

MATRICOLA

5462414